

סמינריון

¹Learning Personalized End-to-End Goal-Oriented Dialog

מגישים

יובל עזרא

הדר ראובן

¹ <https://ojs.aaai.org/index.php/AAAI/article/download/4654/4532>. Link to paper.

Learning Personalized End-to-End Goal-Oriented Dialog	1
Preface	3
Abstract	3
Introduction	3
Related Work	5
Personalized Chit-Chat	5
רשת זיכרון מקצה לקצה	7
ייצוג זיכרון	7
פעולת זיכרון	9
מערכת דיאלוג מותאמת אישית	10
מודל הפרופיל	10
מודל ההעדפה	13
דגם משולב	14
אלגוריתם מלא	15
תהיות שלנו לעתיד	15
ניסויים	16
Dataset	16
Baselines	17
הגדרות הניסוי	17
תוצאות	18
ניתוח	19
ניתוח ווקטור הפרופיל	19
ניתוח הזיכרון הגלובלי	19
ניתוח ההעדפה	20
הערכה אנושית	20
מסקנות	21

Abstract

רוב העבודות הקיימות על מערכות דיאלוג מתייחסות רק לתוכן השיחה, תוך הזנחת אישיות המשתמש שהבוט מתקשר איתו - מה שמוביל לכמה בעיות לא פתורות. במאמר זה אנו מציגים מודל מותאם אישית מקצה לקצה להתרכז בהתאמה האישית בדיאלוגים ממוקדי מטרה.

נציג תחילה את מודל הפרופיל "Profile Model", המקודד את פרופילי המשתמש ל-embeddings ומתייחס להיסטורית השיחות ממשתמשים דומים אחרים. כמו כן נציג גם מודל העדפה "Preference Model", שתופס את העדפות המשתמש ושומר אותם כישויות בבסיס הנתונים כדי להימנע מדו משמעות בבקשות (מוצג בהמשך בדוגמא). שני המודלים משולבים יחדיו לתוך מודל שנקרא PERSONALIZED MEMN2N. ניסויים שביצענו מראים כי המודל המוצע מגיע לביצועים איכותיים יותר לעומת שיטות מתקדמות אחרות. בנוגע להערכה האנושית, הוא גם עולה בביצועיו על גישות אחרות במונחים של אחוז השלמת משימה ושביעות רצון המשתמש.

Introduction

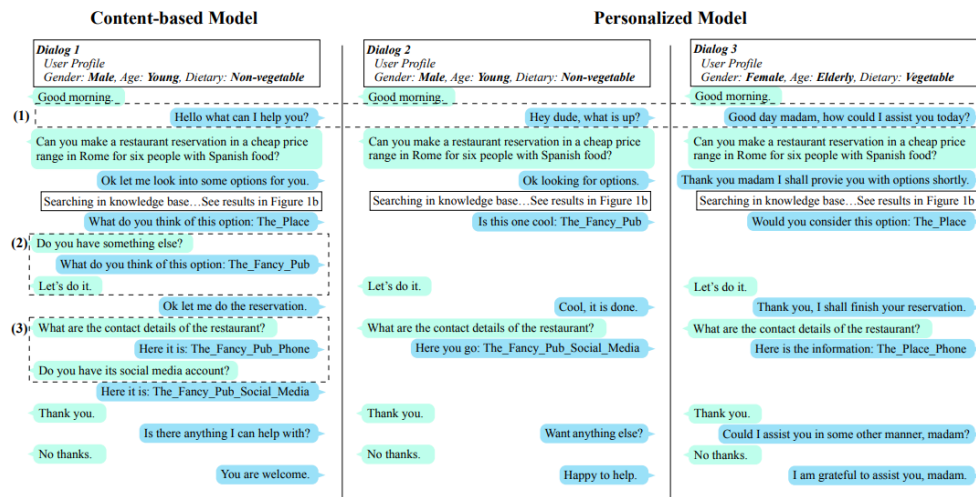
בשנים האחרונות קיים עניין מחקרי גובר באימון מערכת דיאלוג עם מודלים מקצה לקצה. המודלים הללו מאומנים ישירות על דיאלוגים קודמים, ללא הנחה על התחום אליו הם קשורים או על מבנה הדיאלוג.

אחת המגבלות של המודלים המאומנים היא שהם בוחרים תגובות רק בהסתמך על תוכן השיחה, ולכן הם לא מסוגלים להתאים את עצמם למשתמשים בעלי אישיות שונה.

[שאלות מאיתנו מוקפות בסוגריים מרובעים מודגשים. אתה לא מוכרח להתייחס אליהן ברצינות: האם אפשר לקחת בחשבון רק את תוכן השיחה וממנו לבנות, בצורה לא מפורשת, "אישיות" למשתמש? בהתחשב בכך שנתונה היסטוריית שיחות מאותו האדם, ולא רק אחת - או שזה מקביל במובן מסוים לשמירת מידע "אישיותי" על המשתמש והכנסה שלו למערכת החיזוי. מה הם היתרונות והחסרונות לשמירת מידע על האישיות של המשתמש בצורה מפורשת אל מול.. צורה מרומזת, לדוגמא, עם היסטוריית שיחות גלובלית ממשתמשים שקיבלו תוצאות דומות. אולי זה משתלם כי אם הפרופיל מפורש (או הפיצרים שהוא נבנה מהם) הוא יכול אולי לעבור מפרויקט לפרויקט ולקבל עוד שימוש, חיזוק או שינוי ממודלים אחרים שקשורים לדברים אחרים. כמו פרופיל גלובלי כזה? סתם אינטואיציה.]

באופן נקודתי, בעיות נפוצות במודלים מבוססי תוכן מכילות:

- (1) חוסר יכולת להתאים את סגנון השפה בצורה גמישה - כמו כינויים וסגנונות שפה.
- (2) חוסר מדיניות שיחה דינמית המבוססת על פרופיל בן השיחה - כישלון בסיפור האפשרות הטובה ביותר עבור המשתמש הספציפי הזה.
- (3) חוסר היכולת להתמודד עם בקשות דו משמעיות של המשתמשים.



(a) Example dialogs

	Price	Location	Number	Cuisine	Phone	Social Media	Type
➔ The Place	Cheap	Rome	6	Spanish	The Place_Phone	The Place_Social_Media	Vegetable
➔ The Fancy_Pub	Cheap	Rome	6	Spanish	The Fancy_Pub_Phone	The Fancy_Pub_Social_Media	Non-vegetable
.....							

(b) Searched results

איור 1 ממחיש את הבעיות הללו באמצעות דוגמא. השיחה מתרחשת בתרחיש של הזמנת מקום במסעדה. ניתן לראות שהתשובות של המודל מבוסס התוכן הן תשובות משעממות ופשוטות, ולא מסוגלות להתאים כינויים וסגנונות שפה כמו מודל המותאם אישית. בנוסף, בשלב ההמלצה, המודל מבוסס התוכן יכול רק לספק מועמדים בסדר אקראי, בעוד שמודל מותאם אישית, יכול לשנות את מדיניות ההמלצה באופן דינמי, ובמקרה כזה יכול להתאים לתזונת המשתמש. כמו כן, צירוף המילים "צור קשר" (contact), יכול להתפרש בכמה דרכים - "טלפון" או "מדיה חברתית" על פי המידע במאגרי המידע. במקום לבחור אחד מהם באופן אקראי, המודל המותאם אישית מטפל בדרך המשמעות, בהינתן האינפורמציה במאגרי המידע שאנשים צעירים מעדיפים מדיה חברתית בעוד שאנשים מבוגרים מעדיפים מספר טלפון.

פסיכולוגים טוענים שבמהלך דיאלוג אנשים מנסים להתאים את עצמם לשותפם לשיחה כדי להקל על ההבנה, דבר המשפר את יעילות השיחה. בכדי לשפר את האינטליגנציה של הסוכנים, אנחנו רוצים לטש את המודל כך שיוכל ללמוד וליישם התנהגויות אנושיות כאלו בשיחות.

קיים אתגר גדול בבניית מערכת מותאמת אישית, והוא כיצד לנצל את פרופיל המשתמש כדי לייצר תגובות מותאמות אישית אליו. על מנת להתגבר על אתגר זה, ישנן עבודות קיימות כיום שמבצעות פעולות נוספות על המודל שלהן כדי לשלב את ההתאמה האישית בזמן האיומן. פעולות כאלו כוללות פיקוח ביניים או אימון מקדים של פרופילי המשתמש - אלו הן פעולות מורכבות שגוזלות זמן רב. אך בניגוד אליהם, המודל שלנו הוא לגמרי מקצה לקצה ואינו זקוק לפעולות נוספות.

במאמר זה אנו מציגים מודל-פרופיל (PROFILE MODEL) ומודל-העדפה (PREFERENCE MODEL) על מנת ליישם בפרופילי המשתמש והעדפותיהם. מודל-הפרופיל לומד את אישיות המשתמש בעזרת ייצוג פרופיל, ומשתמש בזיכרון גלובלי כדי לאחסן את הקשרי השיחה של משתמשים אחרים עם פרופילים דומים. בדרך זו, המודל יכול לבחור סגנון שפה מתאים, ולשנות את מדיניות ההמלצות בהתבסס על פרופיל המשתמש.

על מנת לטפל בבעית הדו משמעיות, מודל-ההעדפה לומד את העדפות המשתמש מבין המשמעויות הרבות שקיימות על ידי בניית קשר בין פרופיל המשתמש ובין המידע הקיים בבסיסי הידע. מכיוון ששני המודלים האלו הם תחת framework שנקרא MEMN2N, ושניהם תורמים להתאמה אישית בהיבטים שונים, אנחנו משלבים אותם לתוך מודל שנקרא: PERSONALIZED MEMN2N. [הערה שלנו: הכנס פרנס לפאוור ריינג'רס כאן]

הניסויים שלנו על קורפוס דיאלוג ממוקד מטרה, ה-dataset של הדיאלוגים המותאמים אישית של bAbI, מראים כי שימוש במידע האישי יכול בצורה ניכרת לשפר את ביצועי מערכת הדיאלוג. תוצאות ה-MEMN2N מתעלות על כל השיטות העדכניות, כך שקיים שיפור של יותר מ-7% במונחי דיוק לכל תגובה. מבחן עם משתמשים אנושיים ממחיש גם כן שהמודל המוצע מוביל לתוצאות טובות יותר, ובפרט יכולת השלמת משימות ושביעות רצון המשתמש גבוהות הרבה יותר.

Related Work

גישות נומריות מקצה-לקצה לבניית מערכות דיאלוג משכו עניין מחקרי רב. מקובל שסוכני שיח כוללים מערכות דיאלוג ממוקדות מטרה, וגם מערכות ובטים לא ממוקדי מטרה (צ'אט).

מודלי Generative Recurrent כמו SEQ2SEQ הראו ביצועים מבטיחים בצ'אט לא ממוקד מטרה. לאחרונה, מודלים מבוססי שליפה שמשתמשים ב-framework של רשת זיכרון הראו את הפוטנציאל שלהם במערכות מכוונות מטרה. למרות שנעשתה התקדמות מתמדת, עדיין קיימות בעיות שצריכים לטפל בהן. רוב המודלים הקיימים הינם מבוססי תוכן - כאלו שאינם מודעים לפרופיל של בן השיחה, ולכן לא מסוגלים להתאים את עצמם לסוגים שונים של משתמשים. מאמצים רבים הוקדשו על מנת להפוך סוכני שיחה לחכמים יותר, על ידי שילוב פרופיל משתמש לדוגמא.

Personalized Chit-Chat

צ'אט מותאם אישית - הניסיון הראשון למדל אישיות הייתה הגישה של Li להקצאת אישיות וסגנון שיחה ספציפי לסוכנים בהתבסס על embeddings של אישיות שנלמדו. Luan תיאר גישה מעניינת שמשתמשת בלמידה מרובת משימות עם נתוני טקסט מותאמים אישית.

מכיוון שבדרך כלל בהקשר של שיחה אין מידע שמותאם אישית באופן מפורש, מודלים קיימים דורשים לרוב תהליכים נוספים על מנת לשלב התאמה אישית בזמן האימון. Qian הוסיף פיקוח ביניים על מנת ללמוד מתי להשתמש בפרופיל המשתמש. Herzig אימן מראש את פרופיל המשתמש עם שירות חיצוני. העבודה שלנו, בניגוד אליהם, היא לחלוטין מקצה לקצה.

גישה נפוצה להיעזרות באישיות בעבודות הללו, היא שימוש במודל שפה מותנה כמפענח התגובות. זה יכול לעזור להקצות אישיות או סגנון שפה לבוטים בצ'אט, אך זה חסר תועלת במערכות דיאלוג ממוקדות מטרה. במקום להקצות אישיות לסוכנים, המודל שלנו מקדיש יותר תשומת לב לאישיות המשתמשים ומנסה לגרום לכך שהסוכנים יתאימו את עצמם לסוגים שונים של בני שיח.

בדיאלוג ממוקד מטרה - מאחר שרוב העבודות הקודמות מתרכזות בצ'אט, שילוב של התאמה אישית ודיאלוג ממוקד מטרה טרם נחקר. לאחרונה, dataset חדש התפרסם והעשיר את משאבי המחקר המיועדים להתאמה

אישית בצ'אטים. לעומת זאת, לא פורסם dataset שאיפשר לחוקרים לאמן מודל ממוקד מטרה עם מידע מותאם אישית עד שקורפוס הדיאלוג המותאם אישית של bAbI פורסם ב-2018 על ידי Faltings ו-Joshi, Mi.

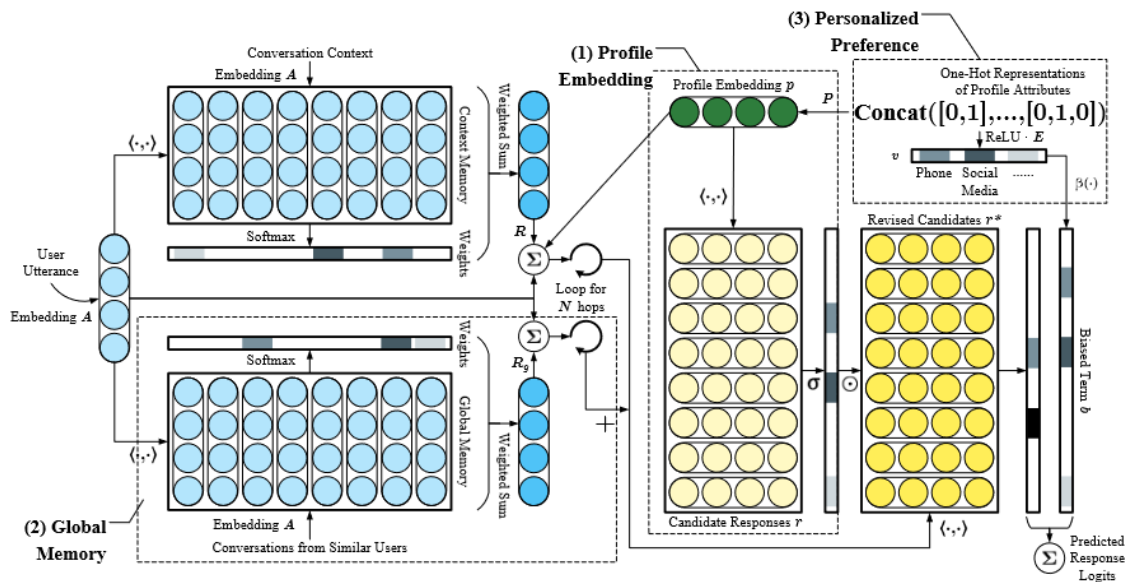
המשימה שלנו היא לעסוק בתוך המודלים של רשת הזיכרון עבור דיאלוג ממוקד מטרה. אנחנו מעשירים את המודלים הקיימים על ידי שילוב וקטור פרופיל ושימוש בהקשרי השיחה ממשתמשים עם תכונות דומות מזיכרון גלובלי.

רשת זיכרון מקצה לקצה²

המודל נבנה על בסיס ה-MEMN2N, אז נסביר בכלליות קצת על המבנה שלו. הוא בנוי משני מרכיבים עיקריים, זיכרון הקשר, והחלק שחוזר את התגובה הבאה. כשהמודל מנהל שיחה עם המשתמש, אמירה מצד המשתמש (utterance) ותגובה מצד הבוט (response), כל אחת בתורה מצורפת לזיכרון.

בכל צעד זמן נתון t יש רצף אמירות ותגובות, כאשר המשתמש אמר t הודעות, $C_1^u, C_2^u, C_3^u, \dots, C_t^u$, והמערכת הגיבה $t - 1$ פעמים $C_1^r, C_2^r, C_3^r, \dots, C_{t-1}^r$. סך הכל הזיכרון הוא הרצף $C_1^u, C_1^r, C_2^u, \dots, C_t^u$, כשהודעות מצורפות לתגובות לסירוגין. נרצה למצוא את התגובה הבאה של המודל, או את C_t^r .

המודל הכולל נראה כך, הוא קצת מפחיד. נתחיל מהחלק השמאלי באמצע, הדרך בה נייצג הודעות בכלל במערכת. התמונה הזו כוללת את שני החלקים של המודל מחוברים יחד - כלומר כולל את החלק שקשור לאישיות המשתמש. נתחיל מלעבור על המודל ללא התייחסות לאישיות ונוסיף אותה בהמשך.



ייצוג זיכרון

[תוספת שלנו, כי לא הכרנו את המונחים bag of words, embedding וכו']

נרצה לייצג את ההודעות שלנו בצורה כלשהי בעלת משמעות עבור המודל. דרכים נאיביות מסוימות לעבוד עם הודעות הן טקסט, אבל קשה לפרסר אותו או להשתמש בו, או וקטורים. נקרא לייצוג הווקטורי של הודעה embedding. כל איבר בווקטור יהיה feature מסוים של מה שנרצה לייצג באמצעות הווקטורים - כלומר, הם סוג של תלויי הקשר. וקטורים מאותו המימד יכולים לייצג דברים שונים לגמרי. לדוגמה בעבור ספה נוכל להשתמש בגודל, נוחות, או מחיר, בצורה טבעית. אולי יהיו features טובים יותר ומשמעותית פחות טריוויאליים, אם נוסיף עוד מוצרים למרחב הווקטורי שלנו.

² [לינק למצגת על המודל עצמו](#)

דרך אחת להמיר מילים לוקטור היא bag of words. ניקח את סט המשפטים באימרה של המשתמש, נחלק אותה למילים (tokenization) ונמיר אותה לוקטור לפי קריטריון מסוים שנקבע מראש. לדוגמא, צורה טריוויאלית תהיה 1 אם מילה מופיעה בסט ו-0 אם לא. נוכל גם לדוגמא לספור כמה פעמים כל מילה מופיעה במשפט.

בכל אופן, הווקטורים הללו גדולים, והם גם דלילים (sparse) שכן הם יכולים להיות מלאים באפסים, למרות המימד הגדול שלהם. הם לא מתייחסים לסדר של המילים במשפט או להקשר שהן נאמרו בו ביחס למילים האחרות. בנוסף, גם אין משמעות "מרחקית" לפעולות כמו חיסור או כפל ווקטורים כאלו. איך נחפש מרחק בין משפטים?


נוכל להשתמש אם כך גם ה-word embedding. ה-features כאן יהיו קצת שונים, וניצור embedding לכל מילה בנפרד. בעזרתן נבנה embedding למשפט ונוכל אחר כך גם לשלב אותו עם הקשר. ניעזר במטריצת הטמעה A - מטריצה בה כל עמודה מייצגת embedding של מילה, כשהאורך שלה הוא כאורך מימד ה-embedding שלנו והרוחב שלה הוא כגודל אוצר המילים מהקורפוס.

הבנו שדרך אחת להשיג הטמעות היא בעזרת מודל סיווג. כמה שכבות לפני הסיווג "נחתוך" את המודל וניקח את התוצאה מהשכבה שנוצרה - היא תהיה וקטור ההטמעה שלנו. את הווקטורים הללו נוכל להכניס כקלט למודלים כלליים אחרים, כדי להימנע מאימון כמותי מידע רבות וחסכון בזמן.

ניעזר במטריצת ההטמעה A, וב-bag of words שמייצג את ההודעה, וניצור זיכרון הקשר m. נכפול כל bag of words של הודעה במטריצה ונקבל וקטור חדש שיהיה וקטור ה-embedding של משפט, בו נשתמש במודל. נשים לב שלדוגמא אם ה-bag of words מכיל 1 בכל המקומות המתאימים למילים שמופיעות בו נקבל פשוט את סכום ה-embeddings של המילים המרכיבות אותו. זיכרון ההקשר יראה כך:

$$m = (A\phi(C_1^u), A\phi(C_1^r), A\phi(C_2^u), \dots, A\phi(C_{t-1}^u), A\phi(C_{t-1}^r))$$

כאשר ϕ ממפה משפט ל-bag of words ממימד V , שהוא גודל אוצר המילים, ו-A היא מטריצה מגודל $d \times V$ כאשר d הוא גודל ה-embedding של כל מילה. למטריצה m, וקטור הווקטורים, שנוצרה נקרא זיכרון ההקשר.



עד כה, לכל אמרה, המידע על מתי היא נאמרה במהלך השיחה ומי אמר אותה (המשתמש או הרובוט), לא נכללים בתוכן הזיכרון. לכן, אנחנו מקודדים את המידע הזה בתוך מיפוי ה- ϕ , על ידי הוספת מילים חדשות לאוצר המילים, אלו יהיו 1000 מילים המתארות את נקודת הזמן בשיחה, שמקודדות את האינדקס i של האימרה לתוך ה-bag of words, ועוד שתי תכונות $\#u$, $\#r$ שמקודדות האם הדובר הוא המשתמש או הרובוט. סך הכל הוספנו 1002 מילים חדשות לאוצר המילים.

נקודת גם את אמרת המשתמש האחרונה לאיבר שנקרא לו q , וישמש אותנו בהמשך כדי לחשב את ההסתברות לרלוונטיות של כל תגובה, בהינתן היסטוריית השיחה וההודעה הזו. $q = A\phi(C_t^u)$.

פעולת זיכרון

המודל תחילה קורא את הזיכרון על מנת למצוא את החלקים הרלוונטים מהשיחה שהתנהלה עד כה לצורך בחירת תגובת המודל הבאה. ההתאמה בין ה-query של המשתמש לבין כל איבר בזכרון m מחושבת על ידי מכפלה פנימית (inner product) ביניהם, ולאחר מכן נבצע על התוצאה softmax ונשמור את התוצאה בוקטור α . נשים לב שבעקבות הפעלת softmax, סכום כל האיברים בוקטור אלפא הוא 1:

$$\alpha = \text{softmax}((\langle q, m_1 \rangle, \langle q, m_2 \rangle, \dots, \langle q, m_M \rangle))$$

האינטואיציה היא שנעבור על הזיכרון איבר איבר ונכפול אותו בהודעה האחרונה שהמשתמש שלח. מתכונות של word embeddings נקבל במובן מסוים את הדמיון בין ההודעה האחרונה של המשתמש לבין ההודעה הספציפית הזו בזיכרון - ונפעיל softmax כדי לנרמל את התוצאות, ובכך ניתן משקל לכל הודעה לפי כמה היא דומה ל- q . בדרך כלל קוראים ל- α גם attention weights.

בזכות התכונה של softmax שסכום האיברים בו הוא 1, נוכל ליצור ממוצע משוקלל של ההודעות בהיסטוריית השיחה ולקבל הודעה שלוקחת בחשבון גם את ההודעות שרלוונטיות ל- q , לפי הרלוונטיות שלהם, וגם את q . נסמן אותו ב- o . נפעיל גם העתקה לינארית R על הממוצע המשוקלל, כאשר R נלמד.

$$o = R \sum_i \alpha_i m_i$$

נרצה, אינטואיטיבית, לקבל קונטקסט של כל השיחה - כלומר, לא רק הודעה שדומה להודעה האחרונה ששלחנו, אלא גם את אלו הדומות להודעות שדומות אליה, וכך הלאה. סוג של רכיב קשירות כזה של שיח. לשם כך ננסה לבצע N איטרציות, כשבכל אחת ניצור את הווקטור o , נחבר אותו ל- q של האיטרציה הזו ונתחיל מחדש עם תוצאת החיבור הזו כקלט q . לבסוף נגיע לוקטור ש"קשור" לכל השיחה, וגם להודעות הקשורות להודעות הקשורות לשיחה, וכך הלאה. נקרא לו q_{N+1} . זו תהיה הודעה ש"מייצגת" את השיחה, ואת ההודעה q המקורית.

$$q_{N+1} = q_N + o$$

נחליט כעת איך נבחר את תגובת המודל, בהינתן הווקטור ש"מייצג" את השיחה, ולשם כך נבצע משהו נורא דומה לדרך בה שמרנו את הודעות השיחה הנוכחית ודירגנו אותן ביחס לרלוונטיות שלהן להודעה q . ניצור זיכרון נוסף r שיכיל את ההטמעות של תשובות המודל, כאשר ניעזר במטריצת הטמעה W ובקבוצת הודעות y שמכילה את כל תשובות המודל האפשריות, הכוללת את כל אמרות הבוטים ואת ה-API calls שנוכל להשתמש בהן. באופן דומה נכפול את ה-bag of words של ההודעה y_i במטריצת ההטמעה ונקבל וקטור ש"מייצג" את תגובת המודל הזו.

$$r = (W\phi(y_1), W\phi(y_2), \dots, W\phi(y_c))$$

[האם נוכל להשתמש ב-embeddings שהגיעו מקבוצות שונות של אוצרי מילים? או שזה יהיה חסר משמעות, שכן כשנוסיף מילים לאוצר המילים ה-features ב-embedding יכולים להשתנות, ואז כשנכפול את ה-bag of words במטריצת ה-embedding המתאימות נקבל ווקטורים לא תואמים? אם כן, אוצר המילים V כבר כולל את כל תשובות המודל?]

שאלה נוספת היא מה קורה כשקבוצת התשובות האפשריות שלנו לא מוגדרת מראש. אם נצטרך להוסיף תשובות בדרך אז האם אוצר המילים שלנו יגדל? ואז השאלה הקודמת רלוונטית. [

באופן דומה, אבל בלי אינסוף איטרציות, נעניק משקל לכל תגובה אפשרית לפי הרלוונטיות שלה לווקטור המייצג את השיחה, q_{N+1} , ומשם נחזיר את התשובה המתאימה למקום בווקטור המשקלים המכילה את המשקל הגדול ביותר - התגובה שהמודל מאמין שהכי רלוונטית לשיחה ולהודעה האחרונה של המשתמש.

$$\hat{r} = \text{softmax}(\langle q_{N+1}, r_1^* \rangle, \dots, \langle q_{N+1}, r_c^* \rangle)$$

$$\text{result} = y_i \quad i = \text{argmax}(\hat{r})$$

מערכת דיאלוג מותאמת אישית

זו הייתה סקירה כללית של MEMN2N. עכשיו ננסה להוסיף התייחסות למשתמש, כלומר, מלבד התייחסות בלעדית להיסטוריית השיחה ננסה מפורשות להוסיף מידע שקשור לפרופיל של המשתמש.

ניעזר ב-embedding מפורש לפרופיל ובזיכרון גלובלי המכיל מידע משיחות קודמות עם משתמשים בעלי פרופיל דומה. זה יהיה מודל הפרופיל (PROFILE MODEL). מודל נוסף ינסה לתפוס את ההעדפות של המשתמש במקרים של דו משמעות, כמו באיור 1, ו-"להקפיץ" את תגובות אפשריות שקשורות לאפשרות שמשתמש עם הפרופיל הנתון כנראה התכוון אליה, ולשם כך ניעזר בשיטות בבסיס מאגר מידע. שני המודלים הללו הם בלתי תלויים זה בזה, ואנו חוקרים את השילוב שלהם כ-PERSONALIZED MEMN2N.

מודל הפרופיל

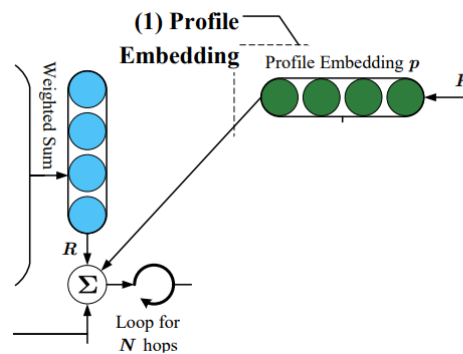
נרצה שלפרופיל תהיה השפעה ישירה על התשובה שתיבחר בלי תלות בהודעה שהמשתמש שלח, אז נערב אותו בחלק של יצירת הקונטקסט לשיחה, ובבחירת התשובה. מודל הפרופיל מורכב משני מרכיבים עיקריים, הטמעת פרופיל (Profile Embedding) והזיכרון גלובלי (global memory).

ראשית כל נדון בייצוג ווקטור הפרופיל. ניעזר במפה בין מפתחות לערכים, כשהמפתחות יהיו ה-feature-ים שלנו. המפה תמפה כל feature לערך שלו, לדוגמא, גיל יכול להיות מפתח, וערך אפשרי עבורו יהיה 20. לדוגמא, מפת פרופיל יכולה להראות כך:

$$\{(Gender, Male), (Age, Young), \dots, (Dietary, Non - vegetable)\}$$

כדי לייצג את המפה ניעזר ברעיון של embedding. בעבור כל מפתח נסתכל על רשימת כל הערכים האפשריים שהוא יכול לקבל, ובכך נייצג אותו כ-one hot vector. בעבור גיל, לדוגמא, כל שאר האפשרויות יהיו 0 והאינדקס המתאים ל-20 יהיה 1. נשרשר את כל הווקטורים שנוצרו מכל המפתחות ונקבל וקטור גדול שייצג את פרופיל המשתמש, a .

[ההנחה כאן היא שהמשתנים שלנו בדידים? מה יקרה אם נרצה לעבוד עם משתנים רציפים? או עם סט בדיד אבל ממש ממש גדול? כמה זה סקלבי?]



נרצה לשלב את וקטור הפרופיל ישירות בחישוב ההודעה ש"מייצגת" את השיחה, ובנוסף אפילו גם בדירוג התגובות הרלוונטיות ישירות, אבל המימד שלו לא מתאים - כרגע הוא שרשור של המון ווקטורי one hot, כשהגודל שלו הוא כסכום הגדלים. אז ניעזר בהעתקה לינארית P וניצור את הווקטור p שייצג את פרופיל המשתמש בצורה מפורשת.

$$p = Pa$$

ב-MEMN2N ה-query משחקת תפקיד עיקרי הן בקריאת הזיכרון והן בבחירת התגובה. נעזרנו בה כדי ליצור את q_{N+1} שבעזרתו יצרנו את הוקטור \hat{r} . נשים לב שה-query לא מכיל אינפורמציה על המשתמש, אלא רק מתייחס לתוכן האימרה האחרונה שלו. נרצה לשלב אספקט של התאמה אישית ל- q בכל איטרציה של ה-query.

מאחר והמימדים שלהם מתאימים נוכל להוסיף את p לתוצאת החיבור בכל איטרציה ולתת לו משקל, כך שהוא לעולם לא "יבלע" בקונטקסט השיחה, ותמיד יהיה רלוונטי מאוד גם לאיטרציה הבאה.


$$q_{i+1} = q_i + o_i + p$$

נרצה כאמור גם שהסבירות של תגובה אפשרית להיבחר תהיה מושפעת ישירות מפרופיל המשתמש ללא תלות בהודעת המשתמש, אז נערב את κ בהליך בחירת תשובת המודל - בלי קשר לשילוב שלו בתהליך יצירת ווקטור השיחה. נערוך את התגובות האפשריות אם כך, בהינתן פרופיל המשתמש.

נחשב כמה כל תגובה רלוונטית לווקטור הפרופיל, נפעיל על התוצאה סיגמואיד ונכפול את התוצאה בווקטור התגובה. במילים אחרות, מאחר והסיגמואיד מחזיר תוצאות בין 0 ל-1 הוא יתן משקל לרלוונטיות של תגובה מסוימת לפרופיל, ו"ננרמל" אותם בהתאם לכך. תגובות שלא תואמות את הפרופיל יקבלו משקל נמוך ויקטנו, ונוכל "להיפטר" מתגובות לא רלוונטיות לפרופיל, שבפרט לא צריכות להיות רלוונטיות למשתמש או לווקטור השיחה.

$$r_i^* = \sigma(\langle p, r_i \rangle) r_i$$

כעת החיזוי יתבצע בצורה זהה לחלק הקודם, אחרי ש"נרמלנו" תגובות לא רלוונטיות לפרופיל ושילבנו את הפרופיל ביצירת ווקטור קונטקסט השיחה.



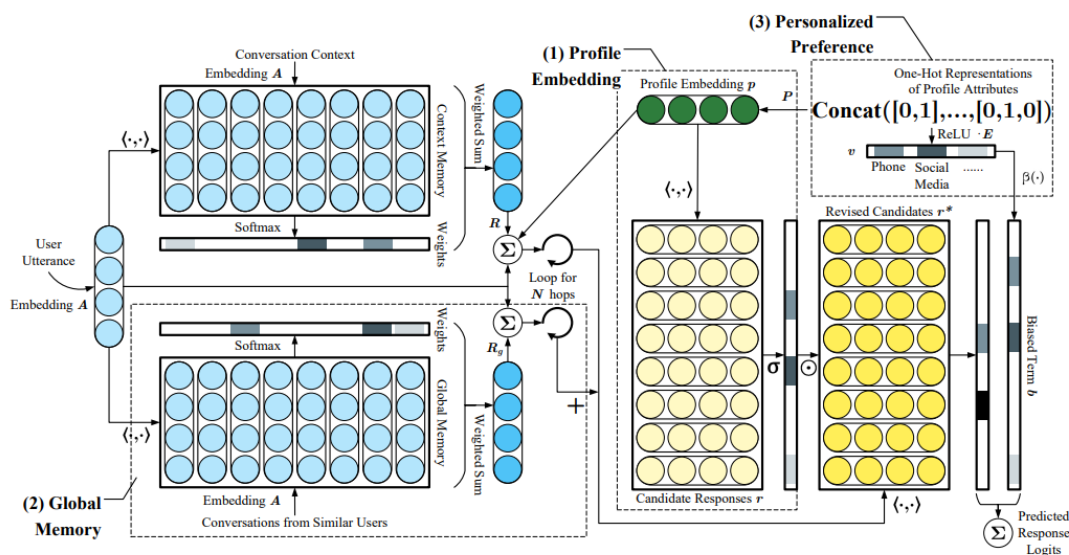
משתמשים בעלי פרופילים דומים עשויים לצפות לתגובה זהה או דומה לבקשה מסוימת. לכן, במקום להשתמש בפרופיל ישירות, באופן מרוזא אנחנו משלבים אינפורמציה מותאמת אישית של בן שיח על ידי שימוש בהיסטוריית שיחות ממשתמשים דומים כזיכרון גלובלי. ההגדרה של "דומה" שונה במשימות שונות. במאמר זה נתייחס למשתמשים בעלי ווקטור פרופיל זהה כמשתמשים דומים.

[איך נוכל לשלב כאן את החלק של דימיון בין משתמשים? לפי threshold של מרחק בין embeddings אולי?]

לזיכרון הגלובלי יש מבנה זהה לשל זיכרון ההקשר ממקודם, אבל הוא מכיל הודעות משיחות שונות במקום רק כאלו מאותה השיחה. חישוב הווקטור ש"קשור" להודעת המשתמש יהיה זהה גם כן, רק ללא שילוב ווקטור הפרופיל שכן אנחנו כבר יוצאים מנקודת ההנחה שההודעות בזיכרון קשורות לפרופיל - שכן הן ממשתמשים דומים.

לבסוף, נחבר את שני הווקטורים המייצגים את השיחה, אחד מצד השיחה הנוכחית והשני מצד כל השיחות הדומות, ונקבל ווקטור ש"מייצג" את שניהם. אותו נעביר לחלק של חיזוי התשובה ממקודם, שכולל את ווקטור הפרופיל.

$$q^+ = q_{N+1}^{(g)} + q_{N+1}$$



איור ארכיטקטורת PERSONALIZED MEMN2N. כסיכום ביניים, קלט המשתמש עובר embed אל הווקטור q . המודל קורא את זיכרון ההקשר ומוצא הודעות רלוונטיות ל- q מהיסטוריית השיחה, בעזרת ווקטור attention מתאים. לאחר מכן הוא מבצע ממוצע משוקלל של ההודעות לפי הרלוונטיות שלהן, מפעיל העתקה לינארית על התוצאה ומחבר לה את q ואת ווקטור הפרופיל p - וכך נעבור לאיטרציה הבאה. ווקטור הפרופיל משתמש גם לתיקון התגובות האפשריות ב- z , זיכרון התגובות.

במקביל חישוב דומה מתבצע בזיכרון הגלובלי עם q רק ללא ווקטור הפרופיל. לאחר מכן נחבר את שתי התוצאות ובעזרתן נחפש את התגובה הרלוונטית ביותר אליהן. לבסוף גם נוסיף bias המתקבל על בסיס העדפת המשתמש, שיקפיץ או יקטין את הרלוונטיות הסופית של התגובות.

מודל ההעדפה

מודל הפרופיל עדיין לא פתר את ההתמודדות למול הדו משמעיות שיש בישויות ה-knowledge base, כמו הבחירה בין "טלפון" אל מול "מדיה חברתית". דו המשמעיות מתייחסת להעדפת המשתמש כאשר יש יותר מאופציה אחת רלוונטית לבקשה ספציפית. נרצה להסיק העדפה כזו על ידי התחשבות ביחס בין פרופיל המשתמש ל-knowledge base.

בהנחה שיש לנו knowledge base שמתאר פרטים (details) על מספר פריטים (items), כך שכל שורה מציינת פריט (item) וכל עמודה מציינת אחד מהפרטים המתאימים אליו. אם כך, ישות הפרט ה- j של הפריט ה- i תהיה האלמנט e_{ij} .

מודל ההעדפה ינסה להשתמש בווקטור הפרופיל וב-knowledge base עם k עמודות, כדי לחזות את העדפות המשתמש על פני העמודות השונות - כלומר, אילו מהפריטים הוא מעדיף עבור כל פרט. ניעזר בווקטור הפרופיל המשורשר a ובהעתקה לינארית E שתמיר אותו למימד גודל העמודות של ה-knowledge base.

$$v = \text{ReLU}(Ea)$$

אנחנו מניחים שהבוט לא יכול לספק יותר מאפשרות אחת בתגובה בודדת, אז אפשרות יכולה להכיל רק ישות אחת לכל היותר. נרצה שההסתברות לבחור תשובה שהמודל יחזיר תהיה מושפעת מהעדפת המשתמש, אם בתשובה יש אזכור לאחת מהישויות ב-knowledge base. לדוגמא, אם התשובה מזכירה את הטלפון של מסעדה מסוימת יהיה אזכור אל העמודה phone של המסעדה הזו.

את ווקטור ה-bias נגדיר להיות באורך כמות התגובות. לכל תגובה שמזכירה ישות מסוימת הוא ייתן "בוסט" מסוים אם ישות זו הוזכרה בקונטקסט השיחה או קשורה לפריט שהוזכר בקונטקסט השיחה, ואחרת, או אם אף ישות לא הוזכרה בתגובה, הוא לא ייתן לה "בוסט".

$$b = \beta(v, r, m) \in \mathbb{R}^C$$

אם בתגובה r_i הוזכרה ישות מסוימת ששייכת לפריט המוזכר בקונטקסט השיחה, והיא בעמודה ה- j שלו אז

$$b_i = v_j$$

ואחרת

$$b_i = 0$$

מכאן, סך הכל נוסיף את ה-bias שנוצר לווקטור ההסתברויות הסופי של משקלי התגובות האפשריות ונקבל:

$$\hat{r} = (< q^+, r_1^* > + b_1, < q^+, r_2^* > + b_2, \dots, < q^+, r_c^* > + b_c)$$

ומכאן פעם נוספת נבחר את התגובה המתאימה לערך המקסימלי בווקטור הנ"ל.

דגם משולב

כפי שציינו קודם, מודל הפרופיל ומודל ההעדפה תורמים להתאמה אישית בהיבטים שונים. מודל הפרופיל מאפשר ל-MEMN2N לשנות את מדיניות התשובה בהתבסס על פרופיל המשתמש, אך נכשל ביצירת קשר ברור בין המשתמש ל-knowledge base, ועל פער זה מגשר מודל ההעדפה בעזרת למידת העדפות המשתמש בהתבסס על ישויות ב-knowledge base. נשלב את המודלים ונסה למזער cross entropy loss.

Algorithm 1 Response Prediction by PERSONALIZED MEMN2N**Input:** User utterance q , Context memory m , global memory $m^{(g)}$, candidates r and user profile \hat{a} **Output:** The index y of the next response

```

1: procedure PREDICT( $q, m, m^{(g)}, r, \hat{a}$ )
2:    $p \leftarrow P\hat{a}$  ▷ Profile embedding
3:    $q^{(g)} \leftarrow q$ 
4:   for  $N$  hops do
5:      $\alpha \leftarrow \text{Softmax}(q^\top m)$ 
6:      $q \leftarrow q + p + R \sum_i \alpha_i m_i$ 
7:      $\alpha^{(g)} \leftarrow \text{Softmax}((q^{(g)})^\top m^{(g)})$ 
8:      $q^{(g)} \leftarrow q^{(g)} + R_g \sum_i \alpha_i^{(g)} m_i^{(g)}$ 
9:   end for
10:   $v = \text{ReLU}(E\hat{a})$ 
11:   $b = \beta(v, r, m)$  ▷ Bias term
12:   $q^+ = q + q^{(g)}$  ▷ Final query
13:   $r^* = \sigma(p^\top r) \odot r$  ▷ Revised candidates
14:   $\hat{r}_i \leftarrow \text{Softmax}((q^+)^\top r_i^* + b_i)$ 
15:   $y \leftarrow \arg \max_i \hat{r}_i$ 
16: end procedure

```

תהיות שלנו לעתיד

ותהינו לעצמנו בנוגע לכמה דברים שהיו קצת מוזרים, מלבד ההנחות הקצת מוזרות של האלגוריתם וההיוריסטיקות שהוא השתמש בהן, כמו מגבלה hardcoded על גודל המילון והתגובות האפשריות. הדבר הראשון הוא שכמו שאמרת במהלך ההצגה, האלגוריתם דטרמיניסטי. בנוסף לכך הוא לא מעדכן את הפרופיל בזמן אמת - שיכול להשתנות אפילו מהתגובה של הרובוט. ראינו בהצגות אחרות שמצב הרוח של המשתמש יכול להשתנות מהרובוט, וגם שהרובוט יכול לנסות להתאים את עצמו למצב הרוח המצופה מהמשתמש.

תהינו גם אם הרובוט יכול באופן כללי לשאול שאלות שיעזרו לו להבין את מצב הרוח של המשתמש או הפרופיל שלו - סוג של לחקור אותו בזמן אמת, ומשם לבצע פעולות על הפרופיל שהוא למד. או פסיכולוגית להשפיע עליו בכוונה עם תגובות מסוימות כדי להוביל את המשתמש לפעולות מסוימות. על איזה מרחב מדגם צריך לאמן את הפרופילים, ומתי? (כמו לדוגמא כשראינו שאימנו מודל רק על חלק מאוכלוסייה מסוימת במקום נורא מסוים בעולם).

ניסויים

Dataset

Dataset הדיאלוגים המותאמים אישית של bAbI הוא קורפוס דיאלוג רב פנויות שהורחב מ-dataset הדיאלוגים של bAbI. הוא מציג פרופיל משתמש נוסף המשוך לכל דיאלוג ומעדכן את האימרות ואת ישויות ה-knowledge base על מנת לשלב סגנון מותאם אישית.

חמש משימות נפרדות בתרחיש הזמנת מסעדה הוצגו עם ה-dataset. כאן נציג אותן בקצרה להבנה טובה יותר של הניסויים שביצענו.

משימה 1: שימוש בקריאות API

המשתמשים מבצעים queries המכילים כמה מקומות ריקים שצריך למלא. הבוט חייב לשאול את השאלות המתאימות על מנת למלא את השדות החסרים ולבצע קריאות API נכונות.

משימה 2: עדכון קריאות API

המשתמשים עשויים לעדכן את בקשותיהם והבוט חייב לשנות את קריאות ה-API בהתאם.

משימה 3: הצגת אפשרויות

בהינתן בקשת משתמש, נעשות קריאות ל-knowledge base והתשובות שחוזרות מתווספות להיסטורית הדיאלוג. מטרת הבוט היא למיין את האופציות בהתבסס על כמה המשתמשים אוהבים את המסעדה. הבוט חייב להיות מודע לפרופיל המשתמש ולשנות את אסטרטגיית המיון בהתאם, על מנת למלא את המשימה.

משימה 4: אספקת מידע

המשתמשים מבקשים מידע מסוים בנוגע למסעדה, ויכולה להיות יותר מתשובה אחת שעשויה לעמוד בדרישות (למשל: ליצור קשר דרך חשבון המדיה וגם מספר טלפון). הבוט חייב להסיק איזו תשובה המשתמש מעדיף, בהתבסס על פרופיל המשתמש.

משימה 5: דיאלוג מלא

משימה זו מנהלת דיאלוג מלא המשלב את כל ההיבטים של משימות 1 עד 4. הקושי של התאמה אישית במשימות אלו אינו מצטבר. במשימות 1 ו-2, הבוט נדרש רק לבחור את התשובות בעלות משמעות וסגנון שפה מתאימים.

במשימות 3 ו-4 מתבצע חיפוש ב-knowledge base, מה שגורם להתאמה אישית להיות קשה יותר. בשתי משימות אלו, הבוט צריך ללמוד תכונות מותאמות אישית כמו סגנון שפה, וכן אסטרטגיות חיפוש או מיון שונות בעבור פרופילי משתמשים שונים. במשימה 5, אנחנו מצפים לביצועים ממוצעים מכיוון שהיא מאגדת את כל ארבעת המשימות האחרות יחדיו.

ישנן שתי גרסאות שונות של ה-dataset בעבור כל משימה. אחת עם סט מלא המכיל כ-6,000 דיאלוגים ואחת עם סט קטן עם 1000 דיאלוגים, ליצירת תנאי למידה מציאותיים. אנחנו מקבלים את מערך הנתונים שפורסם ב-ParlAI.

Models	T1: Issuing API Calls	T2: Updating API Calls	T3: Displaying Options	T4: Providing Information	T5: Full Dialog
1. Supervised Embeddings	84.37	12.07	9.21	4.76	51.60
2. MemN2N	99.83 (98.87)	99.99 (99.93)	58.94 (58.71)	57.17 (57.17)	85.10 (77.74)
3. Split MemN2N	85.66 (82.44)	93.42 (91.27)	68.60 (68.56)	57.17 (57.11)	87.28 (78.10)
4. Profile Embedding	99.96 (99.98)	99.96 (99.94)	71.00 (70.95)	57.18 (57.18)	93.83 (81.32)
5. Global Memory	99.76 (98.96)	99.93 (99.74)	71.01 (71.11)	57.18 (57.18)	91.70 (81.43)
6. Profile Model	99.93 (99.96)	99.94 (99.94)	71.12 (70.78)	57.18 (57.18)	93.91 (82.57)
7. Preference Model	99.80 (99.95)	99.97 (99.97)	68.90 (68.34)	81.38 (80.30)	94.97 (86.56)
8. Personalized MemN2N	99.91 (99.93)	99.94 (99.95)	71.43 (71.52)	81.56 (80.79)	95.33 (88.07)

טבלה 1 מציגה את תוצאות ההערכה של PERSONALIZED MEMN2N על dataset הדיאלוג המותאם אישית של bAbI. שורות 1 עד 3 הן מודלי baselines, שורות 4 עד 6 הן מודל הפרופיל עם שימוש בווקטור הפרופיל, הזיכרון הגלובלי, ושניהם יחדיו. בכל תא, המספר הראשון מייצג את הדיוק לכל תגובה על הסט המלא, והמספר שמופיע בסוגריים מייצג את הדיוק בקבוצה הקטנה יותר בעלת 1000 דיאלוגים. הדיוק בעבור כל תגובה סופר את אחוז האפשרויות שנבחרו נכון.

Baselines

נתייחס ל-baselines הבאים:

Supervised Embedding Model: קו בסיס חזק בעבור צ'אט וכן בעבור דיאלוג ממוקד מטרה.

Memory Network: ה-MEMN2N הרגיל שתואר בתחילת החלק הקודם. אנחנו מוסיפים את המידע על הפרופיל כאימרה שנאמרה על ידי המשתמש בתחילת כל דיאלוג. באופן זה, ה-MEMN2N הסטנדרטי יכול להבין את אישיות המשתמש במידה מסויימת.

Split Memory Network: המודל מפצל את הזיכרון לשני חלקים - תכונות פרופיל והיסטורית שיחות. התכונות השונות נשמרות כרשומות נפרדות בזיכרון הפרופיל לפני שהדיאלוג מתחיל, וזיכרון ההקשר פועל באופן דומה ל-MEMN2N.

הגדרות הניסוי

הפרמטרים מתעדכנים על ידי אלגוריתם גרדיאנט מואץ, ומאותחלים על ידי מאתחל xavier. אנחנו מנסים שילובים שונים של היפר פרמטרים ומוצאים את ההגדרות הטובות ביותר בצורה הבאה: ה-learning rate הוא 0.001, והפרמטר של ה-momentum שמוצג כ- γ הוא 0.9. הגרדינאטים נחתכים על מנת למנוע התפוצצות גרדיאנטים עם threshold של 10. אנחנו משתמשים בעצירה מוקדמת כמו אסטרטגית רגולריזציה.

המודלים מאומנים בחבילות קטנות של מידע, כאשר גודל כל חבילה הוא 64. מימד ה-embedding של המילים\פרופיל הוא 128. אנחנו קובעים את גודל זיכרון ההקשר והזיכרון הגלובלי (כלומר, מספר האימרות) המקסימלי להיות כ-250 ו-1000 בהתאמה.

הזיכרון יכיל וקטורי אפסים בכל מקום בו לא שמורה אימרה. אבל וקטור הזכרון תמיד יהיה בגודל 250 או 1000 בעבור זכרון ההקשר והזיכרון הגלובלי בהתאמה. אם כמות האימרות עולה על גודל הזיכרון, נשמור רק את 250 האחרונות בעבור זיכרון ההקשר, ובעבור הזיכרון הגלובלי נבחר 1000 אימרות תקינות באופן אקראי.

תוצאות

שורות 4 עד 6 בטבלה מציגות את התוצאות ההערכה של **מודל הפרופיל**. הדיאלוג המותאם אישית עשוי להיות מורכב מדי עבור כמה פעולות פשוטות (כמו משימות 1,2 שלא מתבססות על ה-knowledge base), ונוטות לגרום ל-overfitting של נתוני האימון. הדבר בא לידי ביטוי בכישלון מודל הזיכרון המפוצל במשימה 1 ו-2. למרות שהישגיו עולים על ה-MEMN2N הסטנדרטי בכמה משימות מסובכות, MEMN2N מספיק טוב על מנת להבין את מידע הפרופיל שניתן בפורמט של טקסט פשוט ומנצח את מודל הזיכרון המפוצל במשימות פשוטות יותר.

כדי להתגבר על אתגר זה, אנחנו נמנעים משימוש במבנים מורכבים מדי על מנת לעצב את האישיות. במקום זאת, אנחנו רק מציגים את הפרופיל כוקטור הטמעה או באופן מרומז.

כצפוי, הטמעת הפרופיל וכן גישת הזיכרון הגלובלית מבצעים את משימות 1 ו-2 בדיוק גבוה מאוד וגם עולים על ה-baselines במשימה 3, הדורשת שימוש בעובדות מה-knowledge base בשילוב עם מידע הפרופיל. בנוסף, הביצועים של שילוב הטמעת הפרופיל והזיכרון הגלובלי כפי שתואר בשורה 6 בטבלה, עדיפים במעט משימוש בכל אחד מהם באופן עצמאי. התוצאה מעידה על כך שאנחנו יכולים להשתמש ביתרונות של שימוש בפרופילי המידע באופן מפורש ומרומז בינתיים.

מכיוון שמודל הפרופיל לא יוצר קשר מפורש בין המשתמש לבין ה-knowledge base, כפי שתואר קודם, ייתכן שהוא לא יפתור את נושא הכפילויות הקיימות בין עמודות ה-knowledge base. תוצאות הניסוי תואמות להנחות שביצענו טרם התחלת הניסוי - ביצועי ה-PROFILE MODEL במשימה 4, שדורשים הסרת רב משמעויות מבקשת המשתמש, קרובים במיוחד ל-baselines.

שורה 7 מציגה את תוצאות ההערכה של **מודל ההעדפה**, שמטרתו לטפל באתגר הכפילויות שצויין לעיל. המודל משיג שיפורים משמעותיים במשימה 4 על ידי הצגת ה-bias שנגזר מלמידת העדפות המשתמש.

חוץ מזה, אתגר מיון המסעדות במשימה 3 תלויה במאפייני המסעדה במידה מסויימת. באופן אינטואיטיבי, מאפיינים שונים של המסעדות משוקללים באופן שונה והעדפות המשתמש על פני עמודות ה-knowledge base יכולות להיחשב כמשקולות ניקוד ששימושיות לפתרון משימות. כתוצאה מכך, המודל גם משפר את הביצועים במשימה 3 בהשוואה ל-MEMN2N הסטנדרטי.

אנחנו בודקים הביצועים גם בעבור ה-**PERSONALIZED MEMN2N** שהצענו. כפי שניתחנו קודם, מודל הפרופיל וכן מודל ההעדפה תורמים להתאמה אישית בהיבטים שונים, ולשילובם יש פוטנציאל בלהשתמש ביתרונות של שני המודלים. תוצאות הניסוי מאשרות את ההשערה שלנו, לפיה המודל המשולב משיג את הביצועים הטובים ביותר עם שיפור של מעל 7% (ו-9% בסטים קטנים) ביחס ל-baseline הטוב ביותר עבור משימת הדיאלוג המלאה (משימה 5).

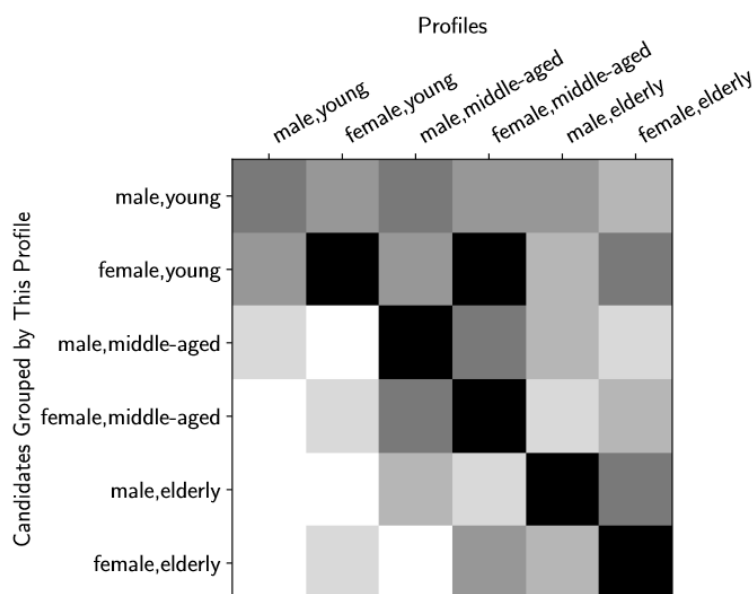
ניתוח

מאחר שה- PERSONALIZED MEMN2N משיג ביצועים טובים יותר מגישות קודמות, אנו מבצעים הערכה על מנת לקבל תובנה נוספת על איך השילוב של הפרופיל והעדפות המשתמש עוזרים לקבלת התגובה המתאימה.

ניתוח ווקטור הפרופיל

מכיוון שאנו משתמשים בווקטור הפרופיל כדי לקבל משקולות שאיתן נתקן את אפשרויות התגובה, נצפה לראות משקלים גדולים יותר עבור מועמדים מתאימים לפרופיל. מאחר שאפשרויות התגובה נאספות מדיאלוגים ממשתמשים שונים, נוכל לחלק אותן ביחס לפרופיל המשתמש. נצפה שבעבור פרופיל מסוים כמו גבר צעיר, נקבל שתגובות רלוונטיות אליו יקבלו משקל גבוה.

נקבץ את האפשרויות על פי פרופילי משתמש, לכל פרופיל ניצור משקולות בעבור התגובות ונאסוף את הערך הממוצע לכל קבוצה. להלן confusion matrix שמציג את משקלי התגובות בהתאם לפרופיל האמיתי של המשתמשים. ניתן לשים לב שהמשקולות על האלכסון גדולות משמעותית מאחרות.



ניתוח הזיכרון הגלובלי

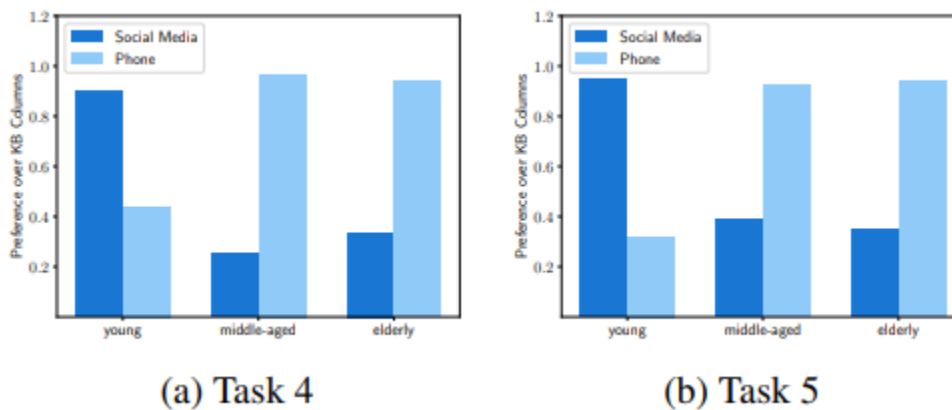
על מנת להמחיש טוב יותר איך הזיכרון הגלובלי משפיע על הביצועים של המודל המוצע, ערכנו ניסוי מבוקר. באופן ספציפי אנחנו בונים מודל בעל רכיב הזיכרון הגלובלי המתואר בחלק אבל האמירות שלו בזיכרון הם ממשתמשים שנבחרו באופן אקראי ולא ממשתמשים דומים. תוצאות ניסוי הבקרה במשימה 5 (דיאלוג מלא) מוצגות בטבלה להלן. המספרים מצביעים על כך שהזיכרון הגלובלי אכן עוזר לשפר את הביצועים.

Models	T5: Full Dialog
Global Memory (similar users)	91.70 (81.43)
Global Memory (random users)	87.17 (78.02)

ניתוח ההעדפה

יש לזכור שאנחנו משתמשים בוקטור v (וקטור ההעדפה) כדי לייצג את העדפות המשתמש בנוגע לעמודות ה- $knowledge$ base. לכן אנחנו חוקרים את הטיעונים הנלמדים שמקובצים לפי תכונות הפרופיל. כפי שניתן לראות באיור להלן, המודל לומד בהצלחה את העובדה שצעירים מעדיפים מדיה חברתית כדרך ליצירת קשר בעוד שאנשים מבוגרים וקשישים מעדיפים מספר טלפון.

התוצאה מראה פוטנציאל גדול ויתרון של מודלים מקצה לקצה. הם מסוגלים ללמוד טיעוני ביניים בעלי משמעות תוך שהם הרבה יותר פשוטים משיטות למידה מבוססות חיזוקים קיימות ומודלים של pipeline למשימה של התאמה אישית בדיאלוגים. האיור מציג את ההערכה של הניסוי המבוקר במשימה 5 אחרי נרמול L2.



הערכה אנושית

כדי להדגים בצורה משכנעת יותר את יעילות גישות ההתאמה האישית על פני מודלים סטנדרטית, בנינו מערכת אינטראקטיבית המבוססת על המודל שהצענו ו-baselines, וערכנו הערכה אנושית. מכיוון שזה לא מעשי למצוא בודקים עם כל הפרופילים שאנחנו צריכים, בנינו באופן אקראי 20 פרופילים עם גילאים, מגדרים והעדפות שונות, ומבקשים משלושה שופטים לפעול לפי התפקידים הנתונים.

שלושת השופטים משתמשים במערכת שבנינו ונותנים ציון עבור השיחות במונחים של אחוז ביצוע המשימה ושביעות הרצון. אחוז השלמת המשימה מייצג עד כמה המערכת השיגה את מטרת המשתמשים. שביעות רצון מתייחסת לשאלה האם התגובות מתאימות לפרופיל המשתמש. הציונים עוברים מיצוע והם בטווח בין 0 ל-1, כאשר 0 זה גרוע ו-1 זה מושלם.

מצאנו כי PERSONALIZED MEMN2N מוביל על MEMN2N baseline ב-27.6% וב-14.3% במונחים של אחוז ביצוע משימות ושביעות רצון בהתאמה, כאשר $p < 0.03$.

מסקנות

במאמר זה הצגנו מודל חדשני מקצה לקצה המיועד להתאמה אישית בדיאלוג ממוקד מטרה. תוצאות הניסוי על datasets וניתוח נוסף מראים שהמודל מסוגל להתגבר על מספר בעיות קיימות במערכות דיאלוג. המודל משפר את יעילות תגובות הבוט עם מידע מותאם אישית וכך עולה בהרבה על השיטות המתקדמות ביותר. בעתיד, ייצוגים נוספים של אישיות מלבד תכונת הפרופיל יוכלו להיות משולבים במודלים של דיאלוגים ממוקדי מטרה. חוץ מזה, אנחנו עשויים לחקור על למידת ייצוגי הפרופיל עבור משימות שאינן תלויות תחום, וכן נתייחס ל-knowledge base עם פורמט יותר מורכב כמו ontologies.

סיכום חוויה

במהלך ההכנה שלנו לקראת הסמינריון ניסינו לסכם את המאמר בצורה יותר ברורה בשבילנו, תוך כדי המחקר. היו במאמר הרבה מילים מושגים שלא יצא לנו לראות לפני תחילת המחקר. הסתמכנו על הסיכום הזה בהכנת ההצגה שלנו. אנחנו מרגישים שזו הייתה טעימה טובה מעולם המחקר האקדמי, והיא באמת גרמה לנו לעבוד קשה כדי לנסות להבין אותה. שמחנו להתנסות בנושא של personalization, ואנחנו נמשיך לקרוא מאמרים אקדמיים נוספים בהמשך בנושא, או בנושאים דומים כמו NLP ומציאת או יצירת features וכדומה. תודה רבה על העברת הסמינריון, שמחנו לקחת בו חלק.

יובל עזרא והדר ראובן.
